

课程报告01：选题相关知识收集

选题

「职业规划知识图谱」 — 基于招聘岗位描述（JD）构建职业规划领域知识图谱，支持职位推荐、就业技能成长规划、就业决策等应用场景。

拟完成的任务

本项目围绕“职业规划”主题，拟完成以下任务：

- 「知识图谱构建」：从大量 JD 中抽取职位、技能、学历、经验等实体及关系，构建职业规划领域知识图谱
- 「职位推荐」：基于用户技能画像，在图谱上匹配推荐适合的职位
- 「技能成长规划」：分析职位间的技能差距，为用户生成从当前岗位到目标岗位的技能学习路径
- 「就业决策支持」：通过图谱提供岗位对比、行业趋势等辅助决策信息

项目仓库

- 「GitHub 组织」：<https://github.com/WHUKE>
- 「项目管理看板」：<https://github.com/orgs/WHUKE/projects/1>
- 「JDParser 知识抽取仓库」：<https://github.com/WHUKE/JDParser>

数据源

主要数据源：招聘岗位描述（JD）

项目	说明
来源	国内互联网大厂官方招聘页面（手动收集）
采集方式	小组成员每人手动收集 20 条 JD，纯文本格式，跑通demo后将使用爬虫批量获取
当前规模	共 120 条 JD（6人 × 20条），存储于 <code>data/raw/</code> 目录
数据格式	TXT 纯文本，包含职位名称、工作职责、任职要求、加分项等
岗位类型	覆盖后端开发、前端开发、数据分析、AI/机器学习、运维、爬虫、游戏引擎等技术方向
后续扩展	Demo 跑通后考虑通过爬虫增量采集更多 JD

候选补充数据源

- 「O*NET (美国职业信息网络)」：全球最大的职业信息知识库，包含职业分类、技能要求、工作活动等结构化数据，可作为图谱 Schema 设计参考
- 「中国职业分类大典」：国内官方职业分类标准，可用于职位类别归一化
- 「招聘平台公开数据」：如 Boss直聘、猎聘等平台的公开岗位信息，用于扩大数据规模

知识收集与构建方法

整体架构



具体方法

1. 正则预解析

使用基于正则表达式的规则解析器，从 JD 文本中提取格式化元信息：

- 职位名称、工作地点、学历要求、工作年限
- 招聘类型、所属部门、职位类别
- 工作职责列表、任职要求列表

特点：格式无关设计，支持多种 JD 文本格式，对每个字段使用多种宽松模式逐个匹配。

2. LLM 深度抽取

使用 DeepSeek 大语言模型对 JD 文本进行深层知识抽取：

- 「细粒度技能拆分」：将"熟悉 MySQL/Redis/MongoDB"拆分为三个独立技能实体
- 「技能熟练度识别」：提取每个技能的要求级别（了解/熟悉/熟练/精通）
- 「技能分类标注」：自动标注技能类别（编程语言/框架/数据库/DevOps工具/软技能等）
- 「正则+LLM互补」：正则负责结构化元信息，LLM负责语义级技能抽取

3. 技能名称归一化

为确保知识图谱中同一技能只有一个节点，建立了 150+ 条技能别名映射表：

- 缩写归一化：JS → JavaScript , K8S → Kubernetes
- 版本归一化：Vue3 / Vue 3 / Vue2 → Vue.js
- 同义归一化：Golang → Go , ES → Elasticsearch
- 自动去重：同一 JD 中重复技能只保留一次

知识表示设计

面向知识图谱设计的结构化输出 Schema:

```
{
  "source_file": "xyh_01.txt",
  "job_title": "全栈开发工程师",
  "location": "广州市",
  "education": "本科",
  "experience": "3-5年",
  "job_category": "前端开发",
  "responsibilities": ["职责1", "职责2"],
  "required_skills": [
    {"name": "JavaScript", "proficiency": "精通", "category": "编程语言"},
    {"name": "Vue.js", "proficiency": "精通", "category": "前端框架"},
    {"name": "MySQL", "proficiency": "熟悉", "category": "数据库"}
  ],
  "preferred_skills": [
    {"name": "Docker", "proficiency": "熟悉", "category": "DevOps工具"}
  ]
}
```

预期知识图谱实体与关系:

实体类型	示例
职位 (Job)	全栈开发工程师、后端开发工程师
技能 (Skill)	JavaScript、MySQL、Docker
地点 (Location)	广州市、上海、北京
学历 (Education)	本科、硕士
职位类别 (Category)	前端开发、后端开发、AI/机器学习

关系类型	说明
REQUIRES_SKILL	职位 → 技能（附带熟练度）
PREFERS_SKILL	职位 → 加分技能
REQUIRES_EDUCATION	职位 → 学历
REQUIRES_EXPERIENCE	职位 → 工作年限
LOCATED_IN	职位 → 地点
BELONGS_TO	职位 → 职位类别

初步抽取的知识规模

首批 120 条数据，共提取出 3217 个技能项

每周推进计划与分工

周次	任务	说明
第1周（本周）	数据收集 + 知识抽取工具开发	每人收集20条JD；完成 JDParse 正则+LLM双模式解析器开发
第2周	数据清洗 + 知识图谱Schema设计	对LLM解析后数据进行清洗并设计图谱 Schema
第3周	知识图谱构建 + 存储	将结构化数据导入图数据库（Neo4j），构建知识图谱
第4周	图谱可视化 + 应用开发	实现图谱可视化界面；开发职位推荐/技能路径规划等应用功能
第5周	集成测试 + 报告撰写	端到端测试；撰写最终报告和演示材料

小组分工

注：具体分工可通过[项目管理看板](#)查看

小组成员与GitHub账号对应如下：

- 汤语涵：<https://github.com/Animnia>
- 邢泽雷：<https://github.com/xingzelei>
- 谢羿衡：<https://github.com/shenxianovo>
- 刘义群：<https://github.com/luckywing1>
- 唐熙雷：<https://github.com/rainstar0320>

- 李嘉轩: <https://github.com/fivekilo>
- 陈宇轩: <https://github.com/gange-niubi>

角色	负责内容
数据收集（全员）	每人从不同公司/平台收集20条JD
知识抽取开发	JDParser 工具开发、LLM prompt 调优、技能归一化
知识图谱构建	Schema 设计、Neo4j 导入、图谱维护
可视化与前端	图谱可视化、交互界面开发
应用逻辑	职位推荐、技能路径规划算法实现
报告与协调	文档撰写、进度跟踪、汇报